深度學習
Pytorch手把手實作
物件偵測YOLOv2

黃志勝
義隆電子人工智慧研發部
國立陽明交通大學 AI學院 合聘助理教授
國立台北科技大學 電資學院 合聘助理教授

YOLOv1的detector怎麼處理

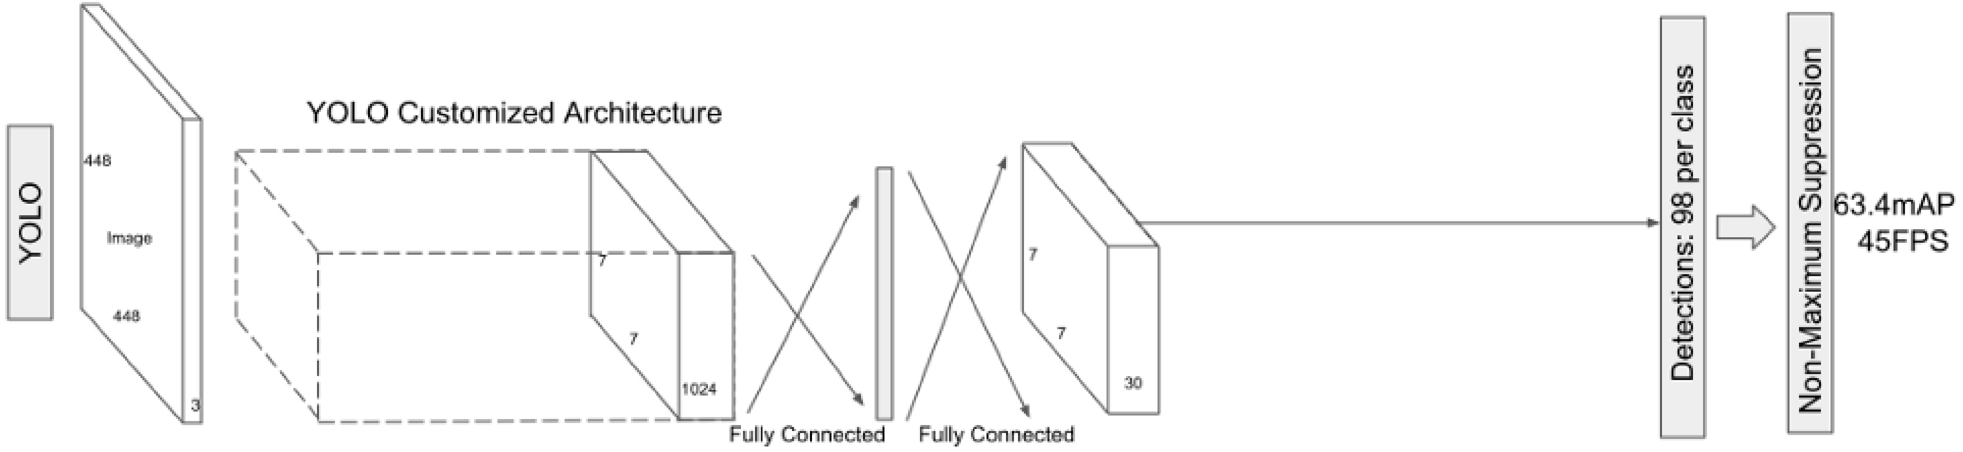

最後一層是7*7*30

7*7就是的grid cell

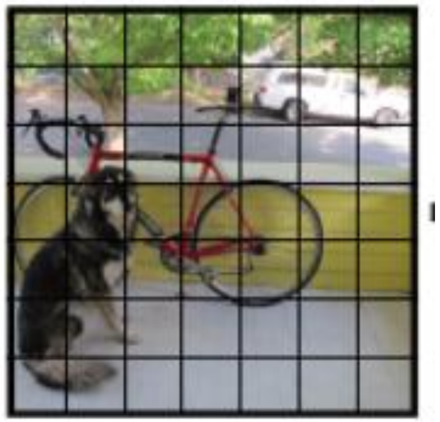

S × S grid on input

30 = 2x5+20
2: 2個Boundarybox
5: 每個Boundarybox (x, y, w, h, confidence)
20:屬於20個類別的機率。

YOLOv1的detector怎麼處理

- 最後一層是7*7*30

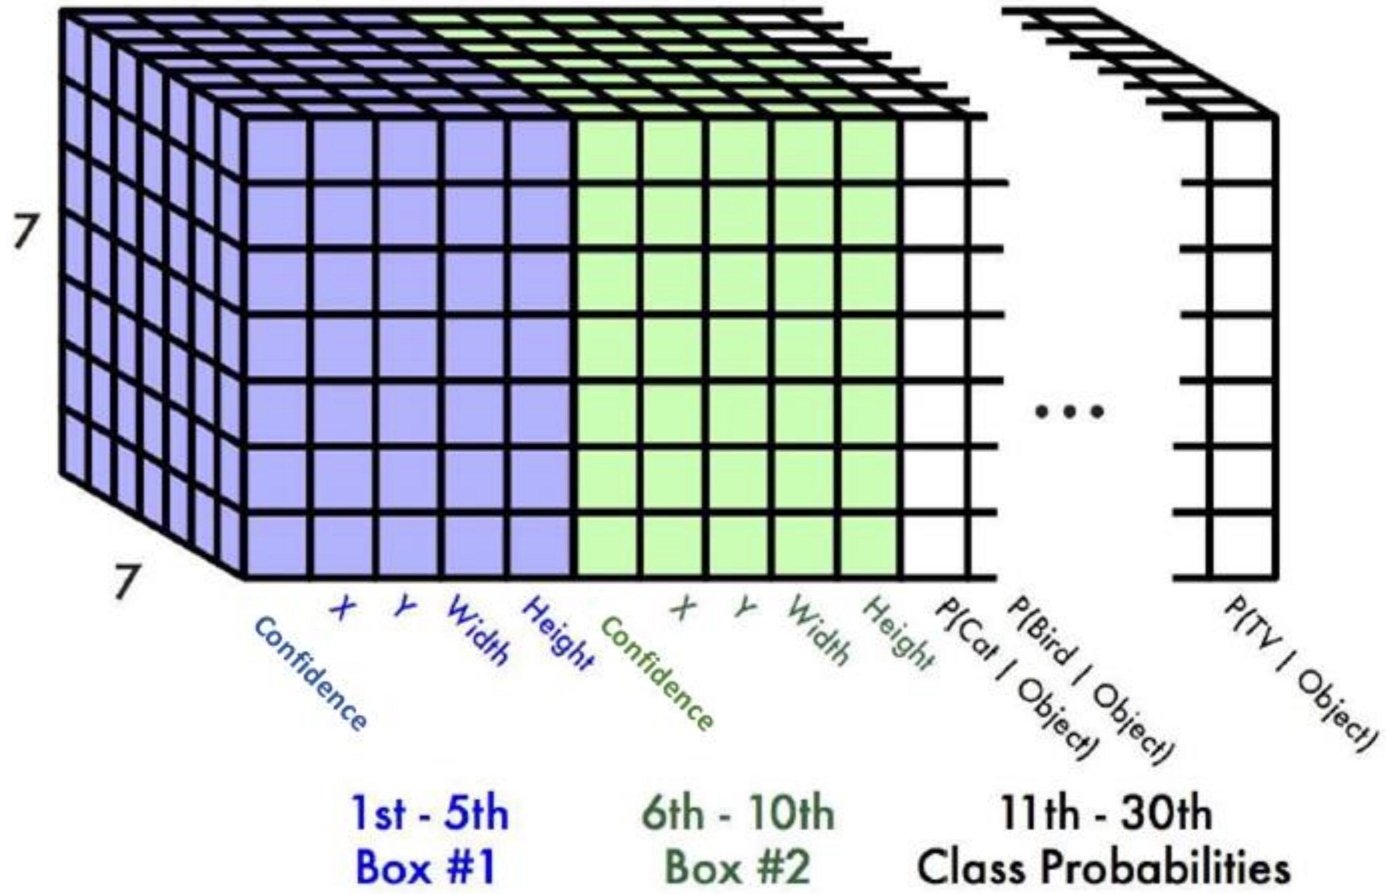

YOLOv1的detector怎麼處理

5: 每個Boundary box (x, y, w, h, confidence)

20:屬於20個類別的機率。

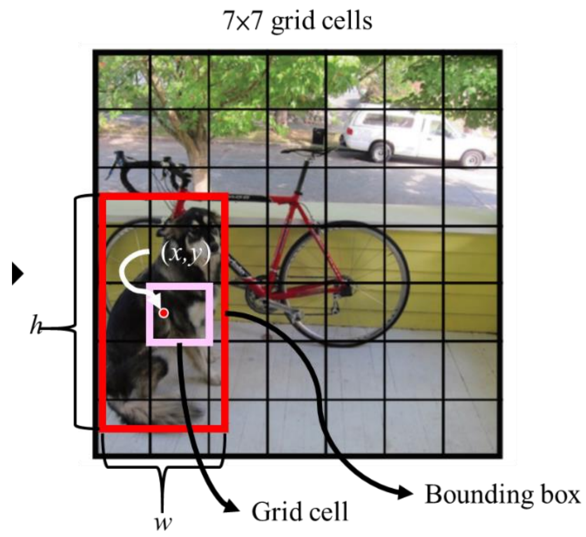

這個物件落在粉紅色框的grid cell
座標為這個grid cell內紅色框這個
Bounding box的中心(x,y)，高寬為h,w。

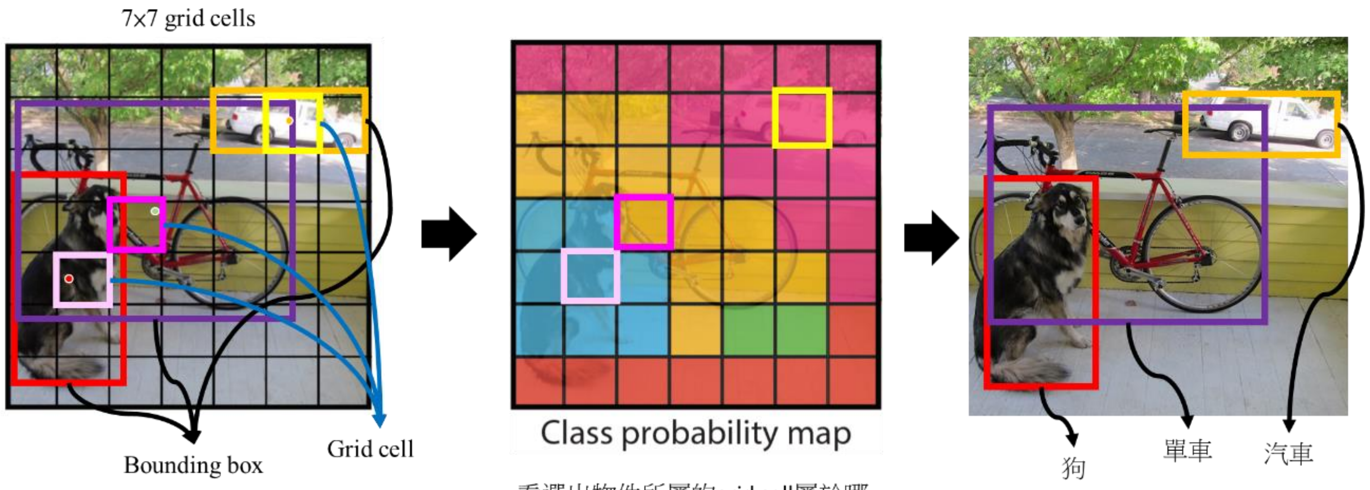

先利用閾值和NMS選出確定是物
件的Bounding box

看選出物件所屬的grid cell屬於哪
一類的機率最大。
水藍色:「狗」的機率最大
黃色:「單車」的機率最大
粉紅:「汽車」的機率最大
橘色:「地板」的機率最大

YOLOv1 loss function

物件的中心座標(x, y)和模型預測BBOX座標$(\hat{x}, \hat{y})$的均方差和

物件的長寬(w, h)和模型預測BBOX長寬$(\hat{w}, \hat{h})$的均方差和

這個grid cell有沒有物件的信心度

這個物件被判斷成每個類別的機率

$$
\begin{aligned}
\mathrm{loss}_{YOLO} = {} & \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \boxed{1_{ij}^{obj}} \left[\boxed{\left(x_i - \hat{x}_i\right)^2 + \left(y_i - \hat{y}_i\right)^2} \right] \\
& + \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^{B} 1_{ij}^{obj} \left[\boxed{\left(\sqrt{w_i} - \sqrt{\hat{w}_i}\right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i}\right)^2} \right] \\
& + \sum_{i=0}^{S^2} \sum_{j=0}^{B} 1_{ij}^{obj} \boxed{\left(C_i - \hat{C}_i\right)^2} + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^{B} 1_{ij}^{noobj} \boxed{\left(C_i - \hat{C}_i\right)^2} \\
& + \sum_{i=o}^{S^2} 1_{i}^{obj} \boxed{\sum_{c \in classes} \left(p_i(c) - \hat{p}_i(c)\right)^2}
\end{aligned}
$$

1_{i}^{obj}: 是物件有出現在 grid cell i。

1_{ij}^{obj}:是在第 i 個 grid cell 的第 j 個 Bounding Box 負責做預測。

是不是有物件

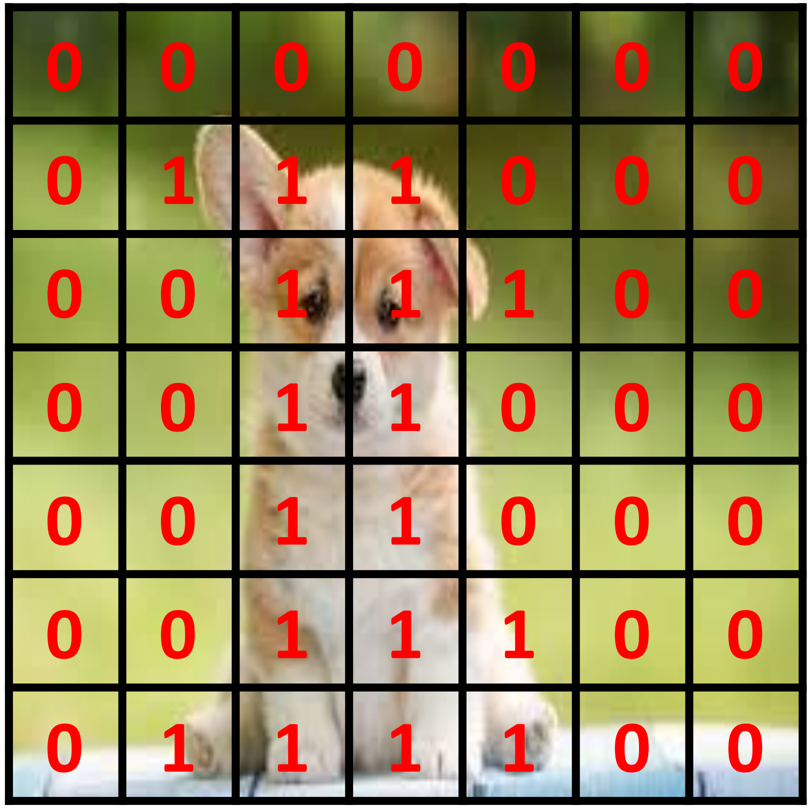

1^{obj}

0	0	0	0	0	0	0
0	1	1	1	0	0	0
0	0	1	1	1	0	0
0	0	1	1	0	0	0
0	0	1	1	0	0	0
0	0	1	1	1	0	0
0	1	1	1	1	0	0

1^{noobj}

1	1	1	1	1	1	1
1	0	0	0	1	1	1
1	1	0	0	0	1	1
1	1	0	0	1	1	1
1	1	0	0	1	1	1
1	1	0	0	0	1	1
1	0	0	0	0	1	1

是不是有物件

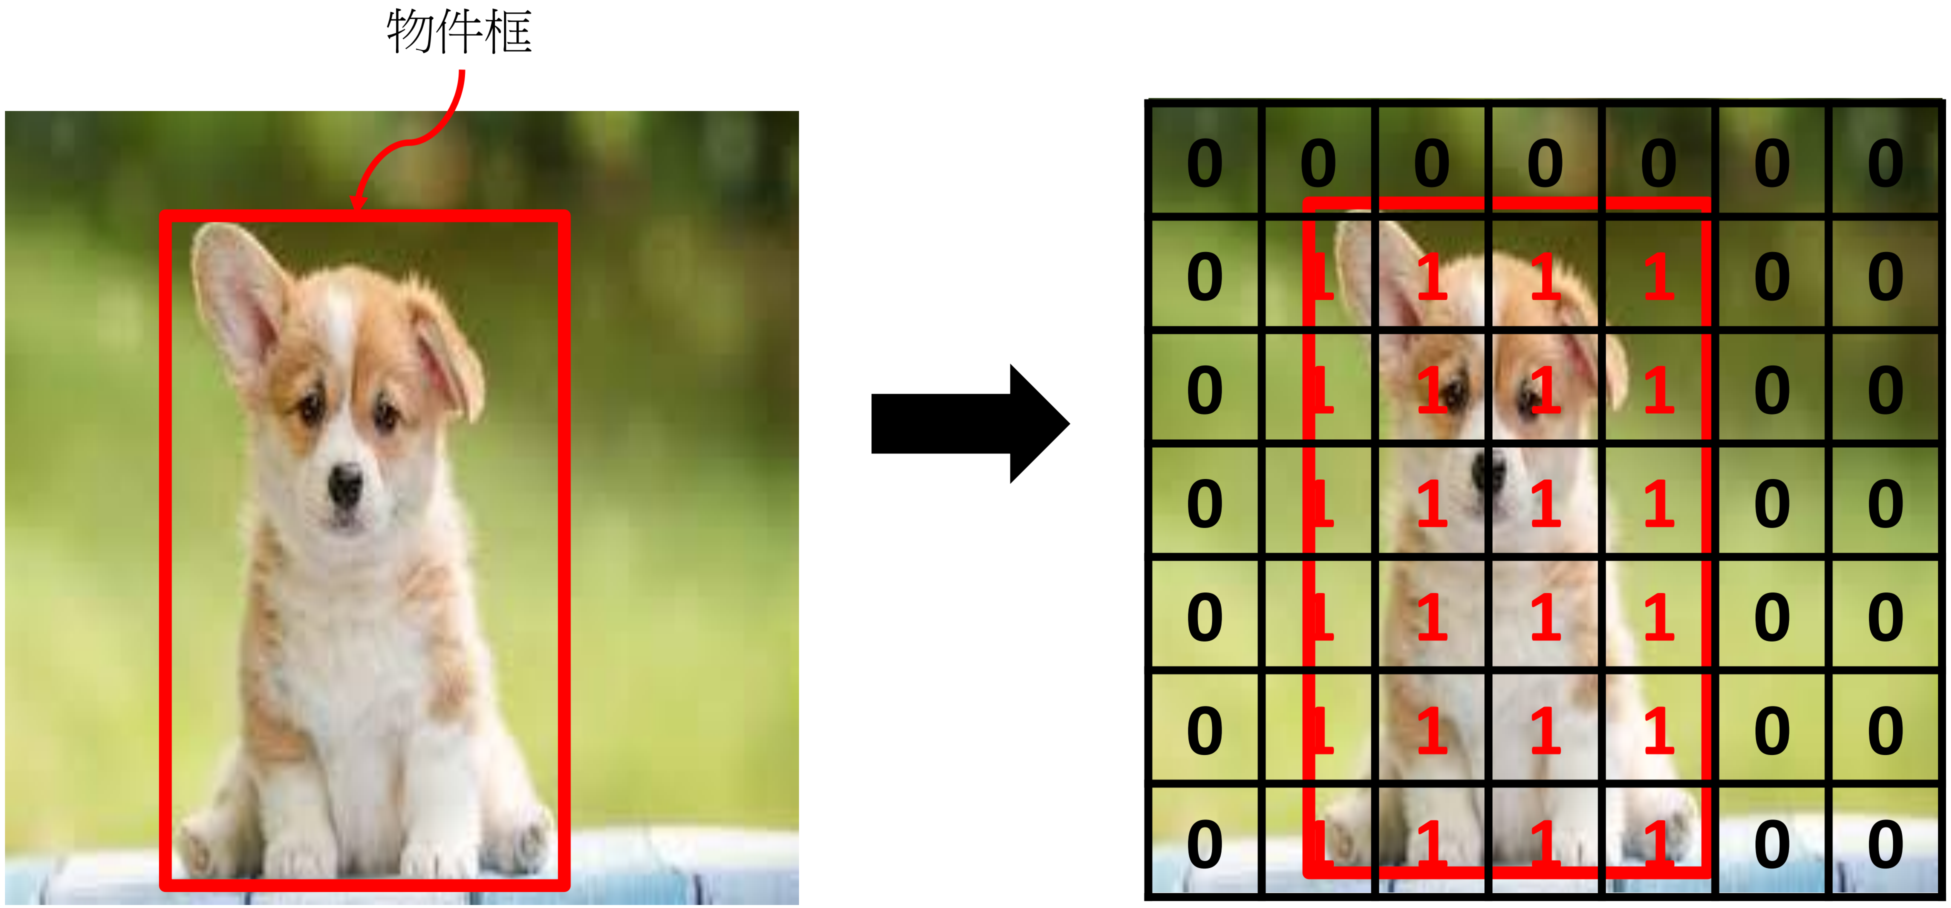

物件框
0 0 0 0 0 0 0
0 1 1 1 1 0 0
0 1 1 1 1 0 0
0 1 1 1 1 0 0
0 1 1 1 1 0 0
0 1 1 1 1 0 0
0 1 1 1 1 0 0

SSD detector

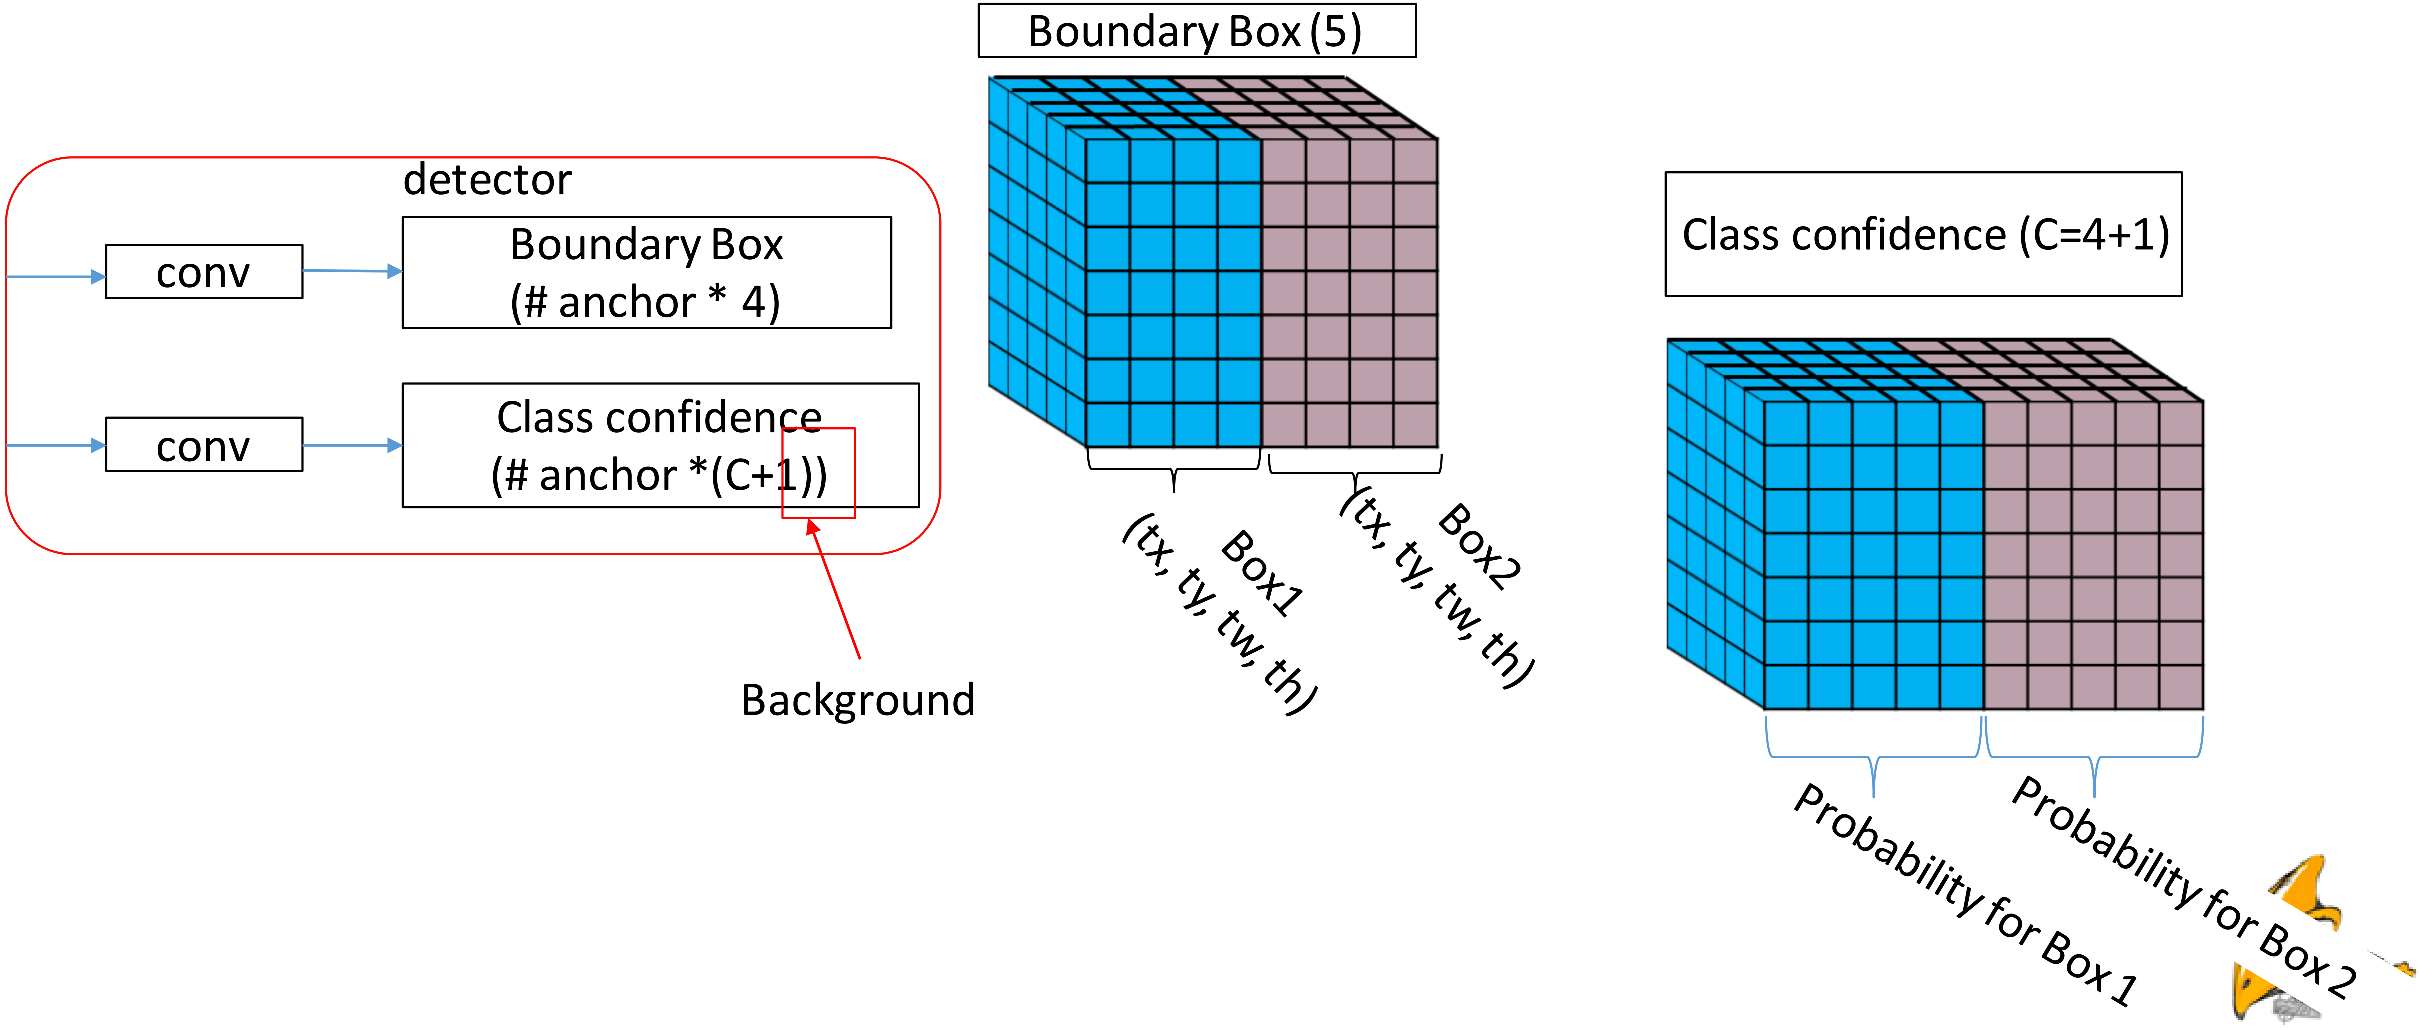

SSD vs YOLO

SSD detector

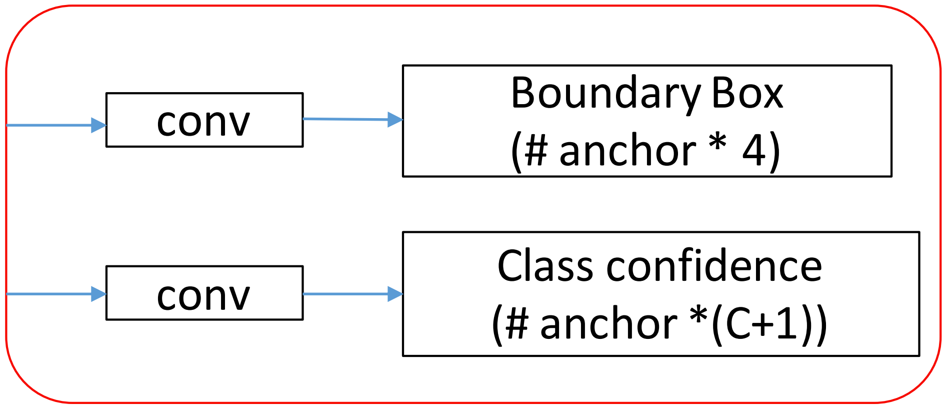

YOLO detector

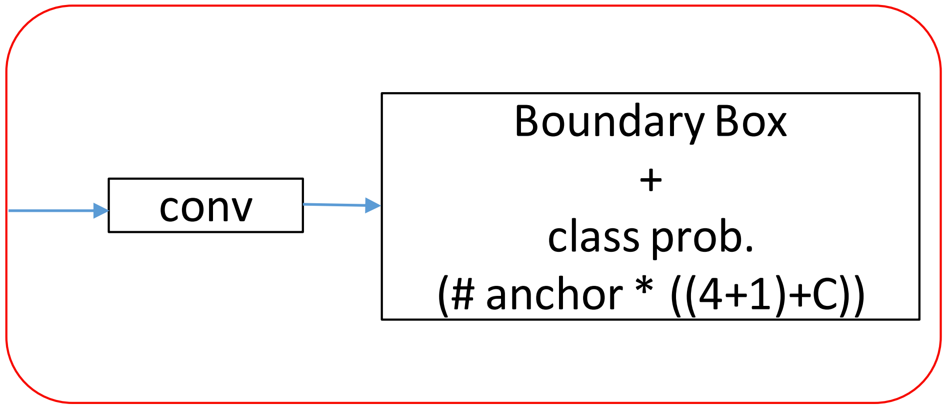

SSD vs YOLO

YOLOv1
 # class =4

- 最後一層是7*7*14

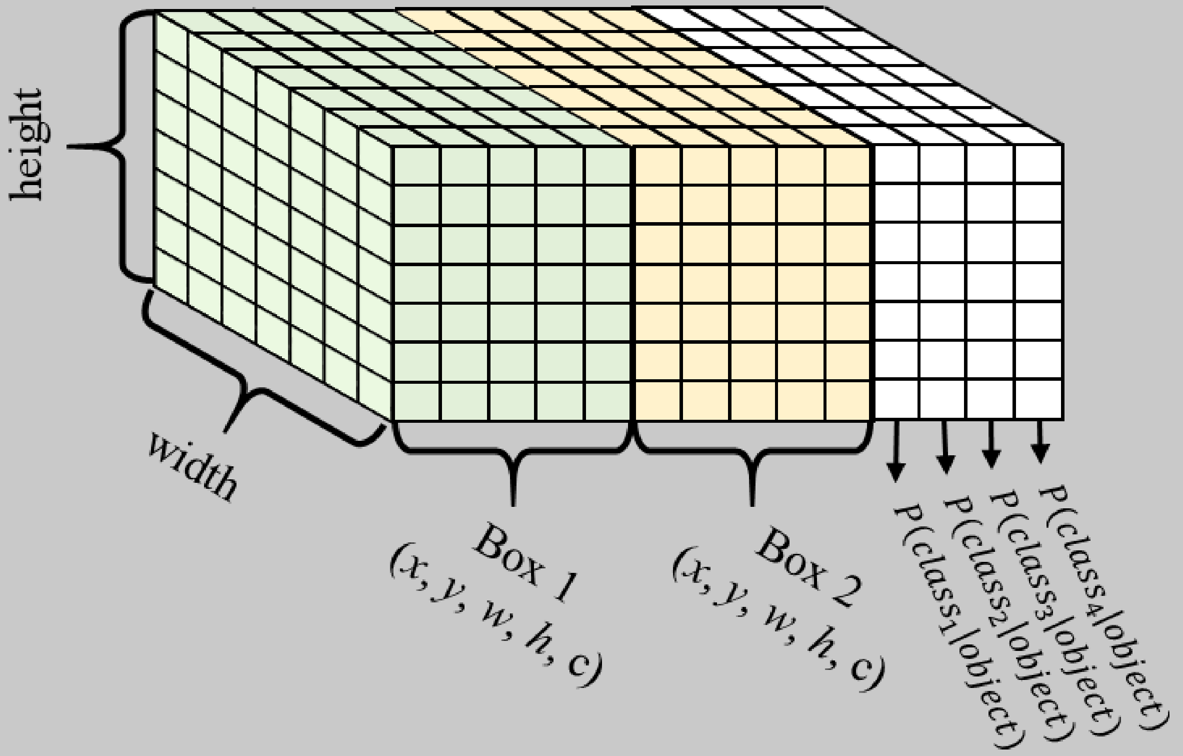

SSD
 # class =4

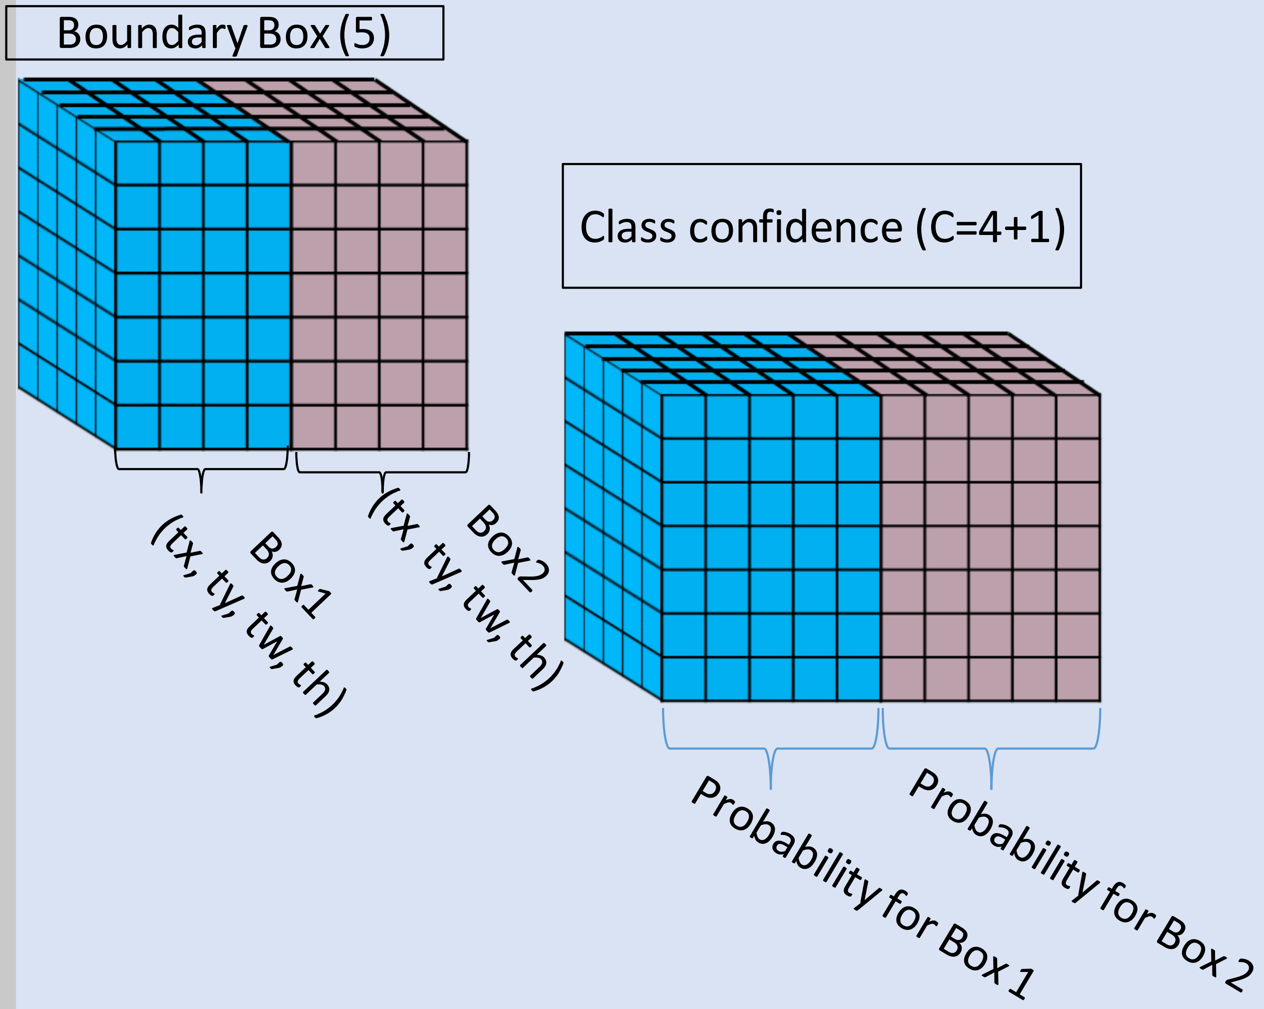

SSD vs YOLO

YOLOv2↑
 # class =4

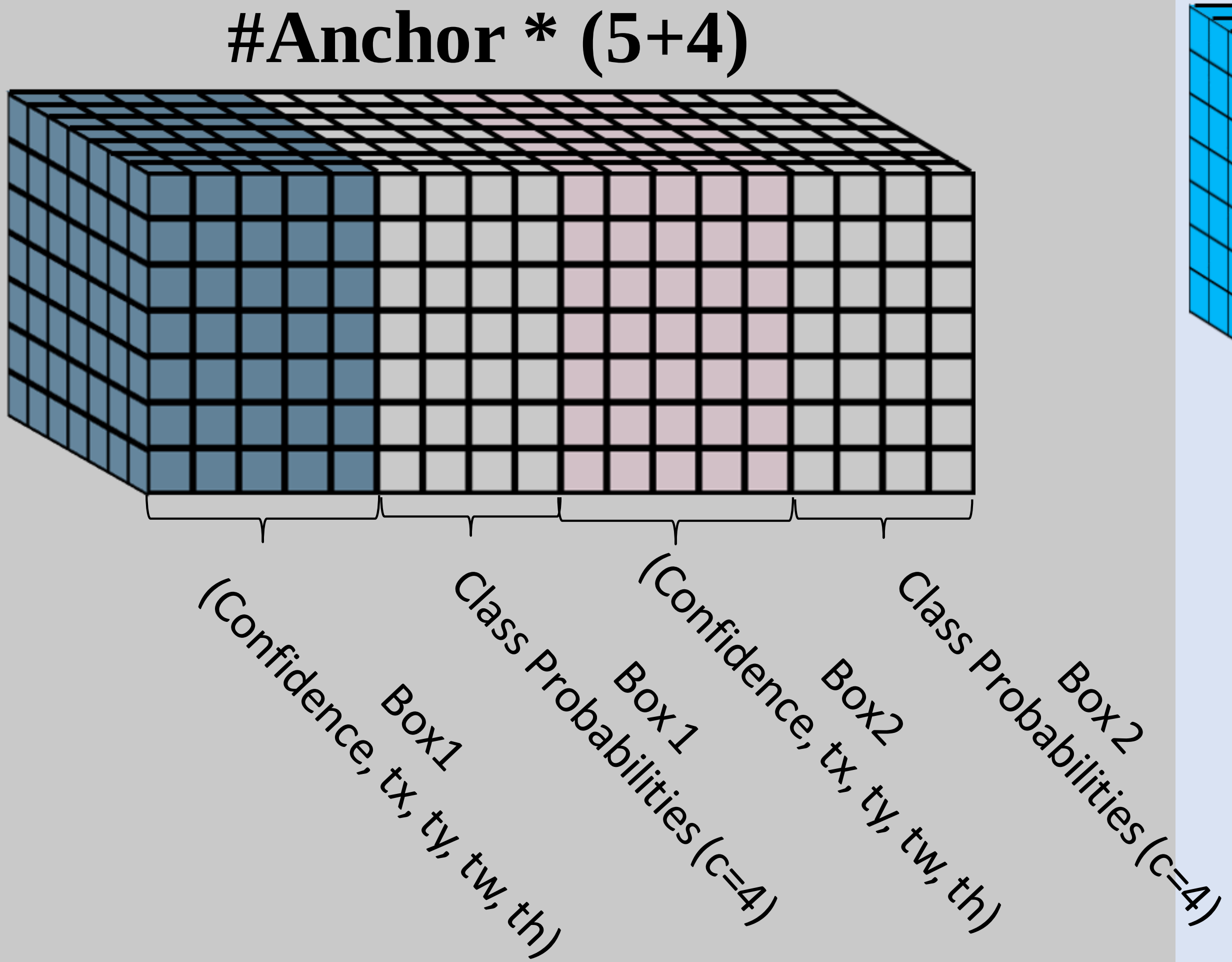

SSD
 # class =4

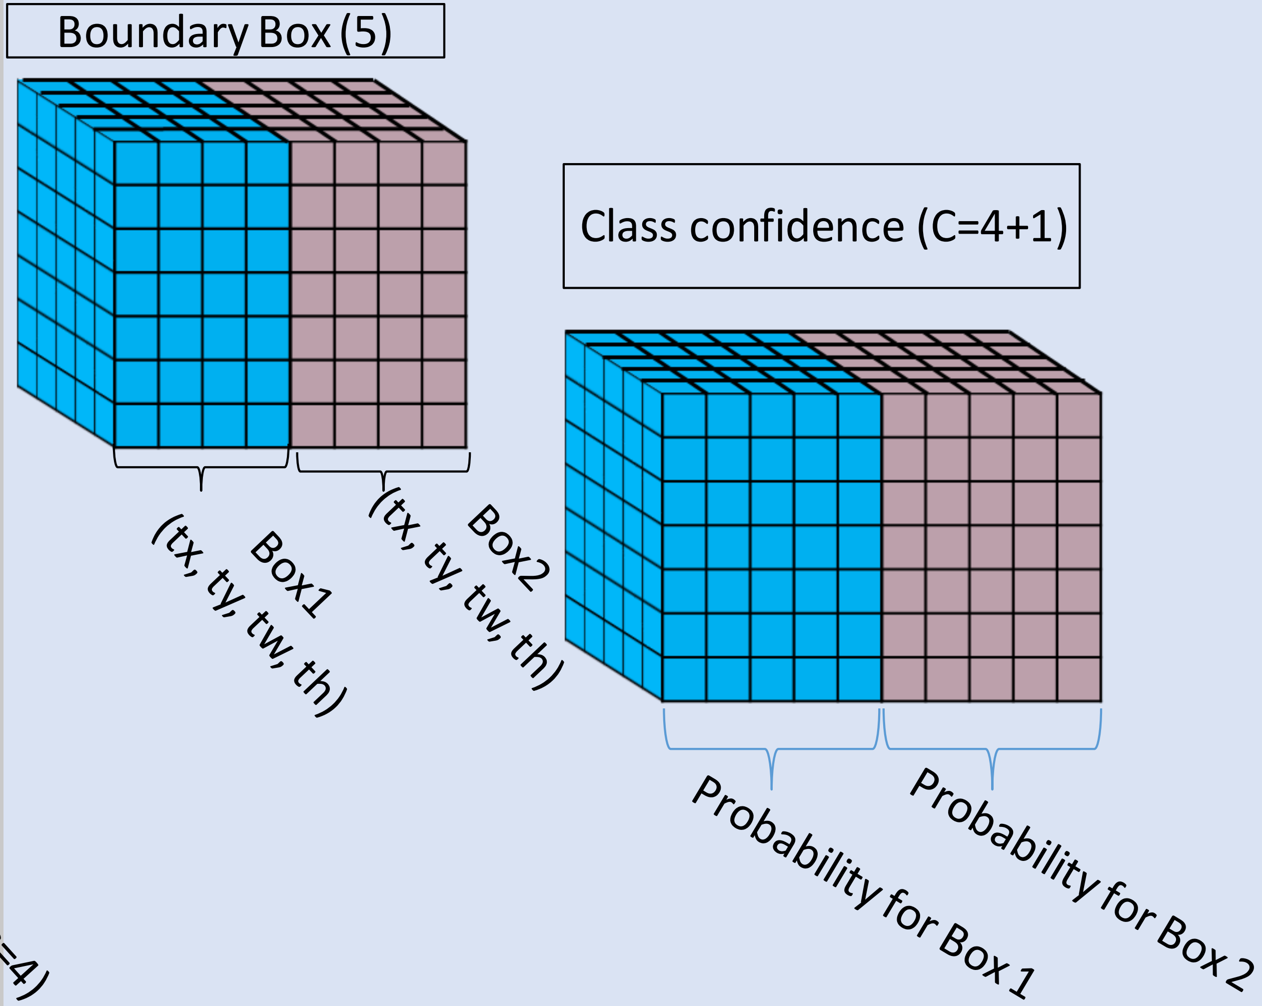

YOLOv1和v2以上

- **YOLOv1: (Confidence, x, y, w, h)**
- YOLOv2个: (Confidence, tx, ty, tw, th)

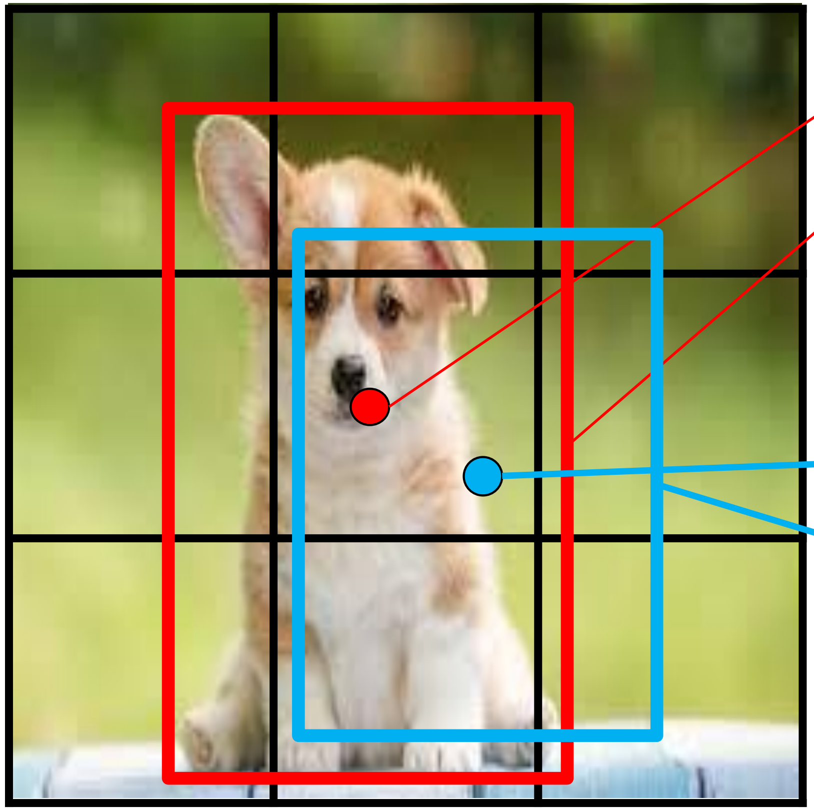

$$(x, y) = (0.5, 0.5)$$

$$(w, h) = (0.4, 0.9)$$

$$(\hat{x}, \hat{y}) = (0.6, 0.7)$$

$$(\widehat{w}, \hat{h}) = (0.3, 0.6)$$

$$(x - \hat{x})^2 + (y - \hat{y})^2 = 0.05$$

$$\left(\sqrt{w} - \sqrt{\widehat{w}}\right)^2 + \left(\sqrt{h} - \sqrt{\hat{h}}\right)^2 = 0.0375$$

YOLOv2後引入Anchor的想法

在最後預測的S*S 的每個grid cell都預設幾個Anchors。

範例為3*3的特徵圖，共有9個grid cells，每個cell內預設3個anchors (紅色、黃色和藍色框)

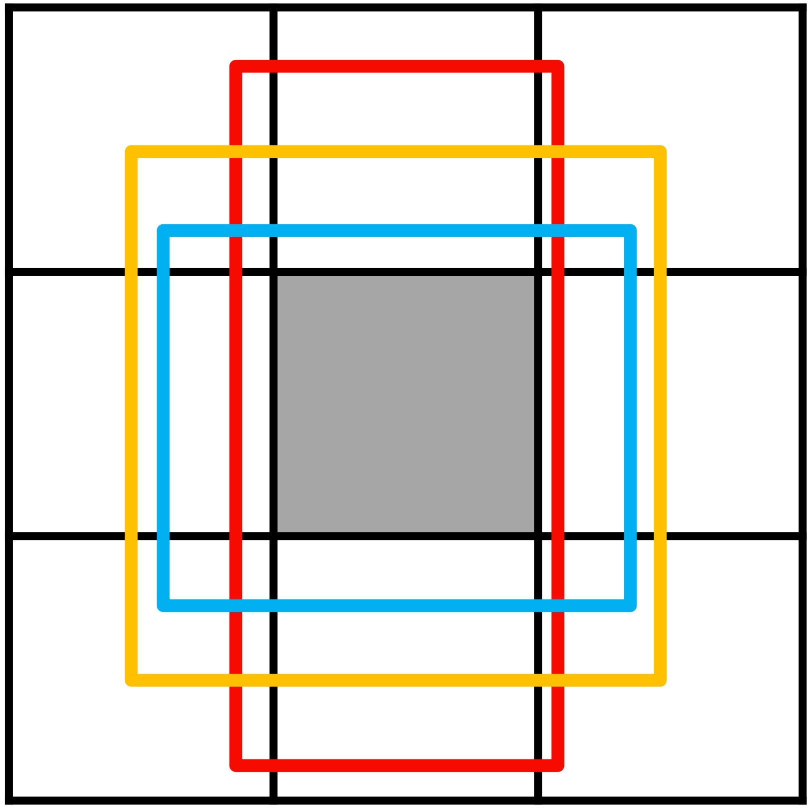

YOLOv2後引入Anchor的想法

在最後預測的S*S 的每個grid cell都預設幾個anchors

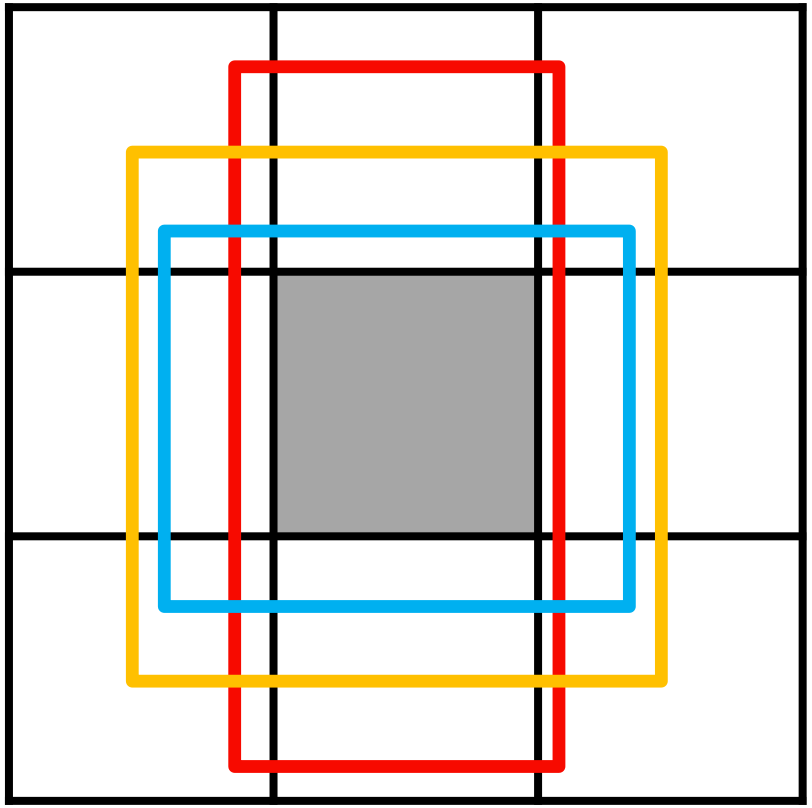

…

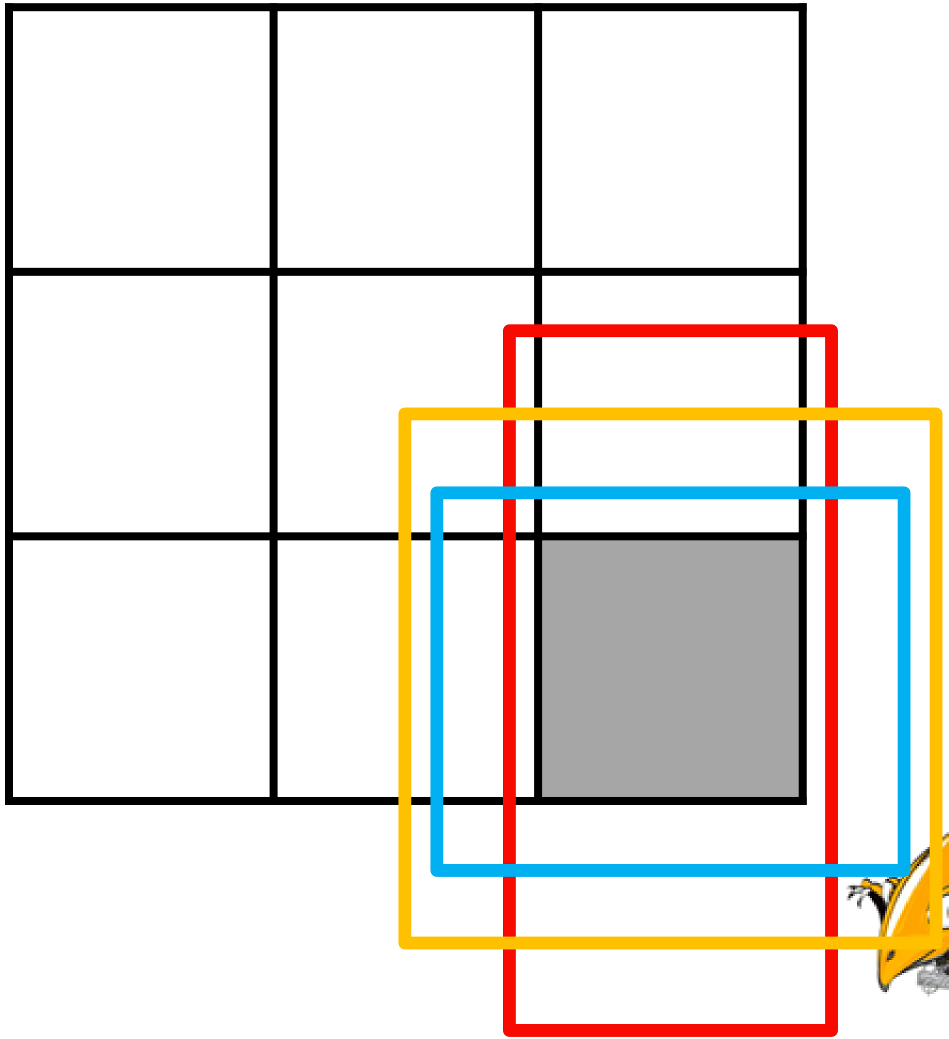

YOLOv2後引入Anchor的想法

不同的物件大小用不同anchors去Fit，所以我們在預測的時候只要去調整Anchor的大小來Fit物件就好。

紅色的Anchor比較適合狗

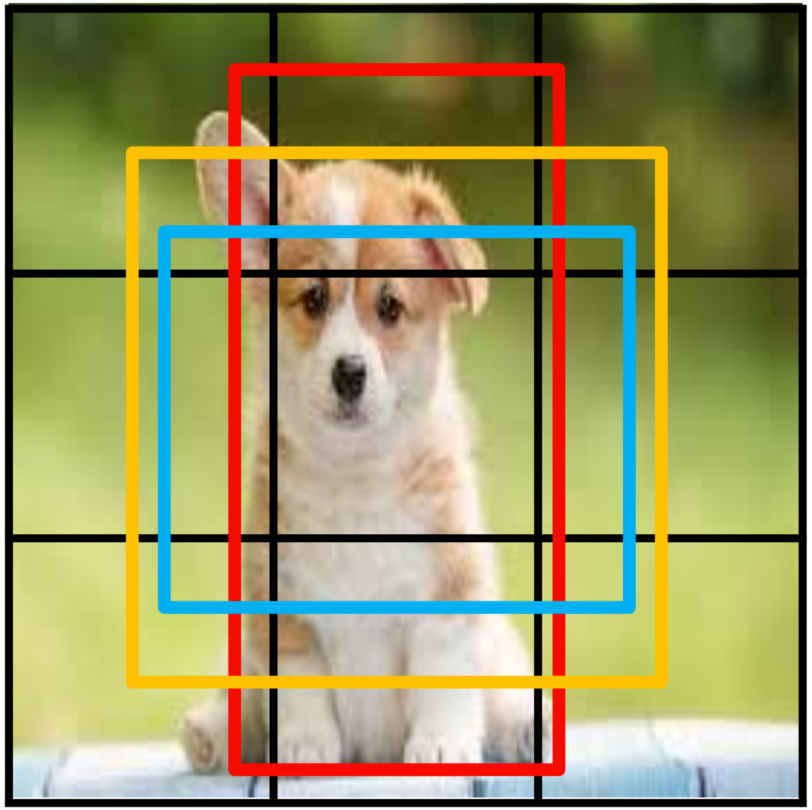

黃色的Anchor比較適合貓

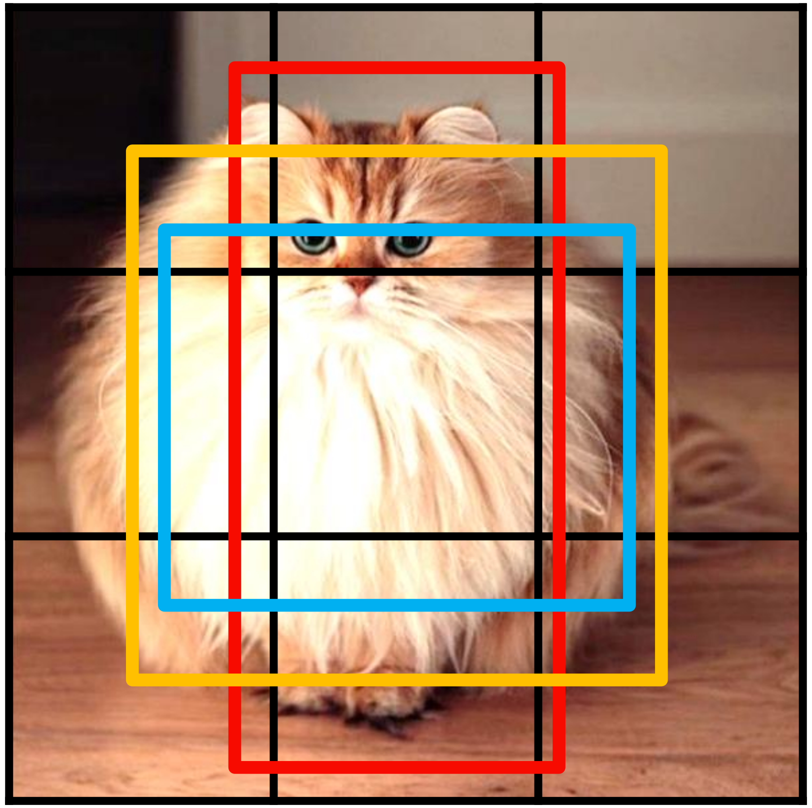

YOLOv2後引入Anchor的想法

不同的物件大小用不同anchors去Fit，所以我們在預測的時候只要去調整Anchor的大小來Fit物件就好。

紅色的Anchor比較適合狗

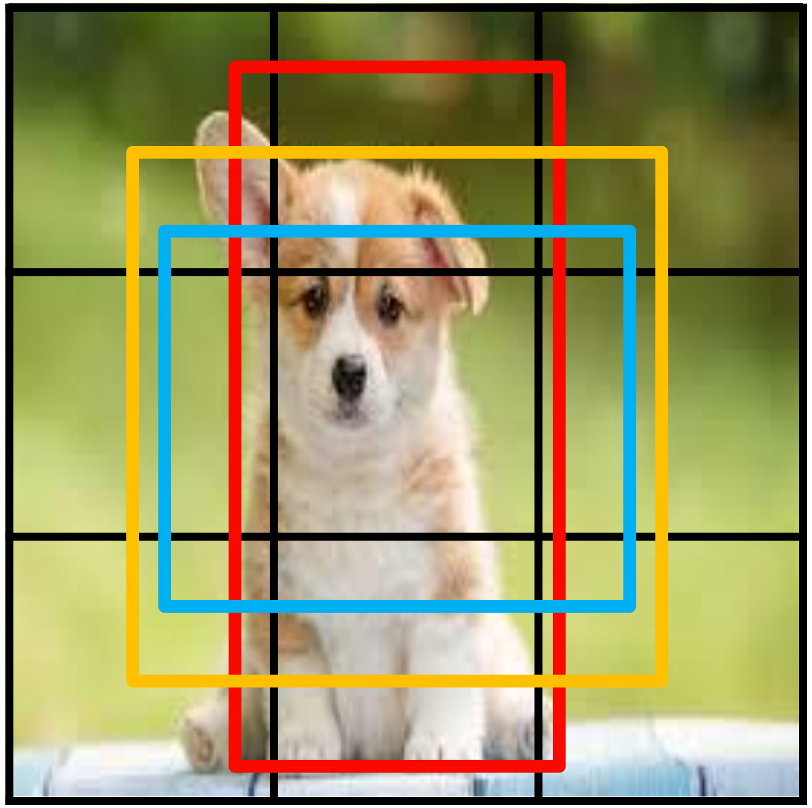

神經網路學習
調整紅色的Anchor去fit狗

紅色anchor高縮小一點，往左下移動一點

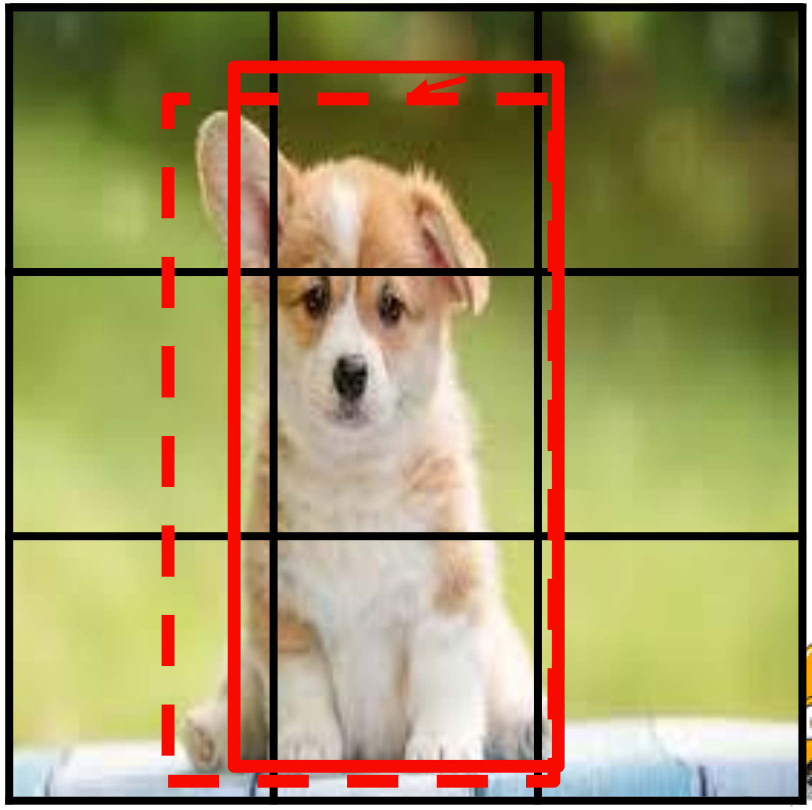

YOLOv2後引入Anchor的想法

不同的物件大小用不同anchors去Fit，所以我們在預測的時候只要去調整Anchor的大小來Fit物件就好。

黃色的Anchor比較適合貓

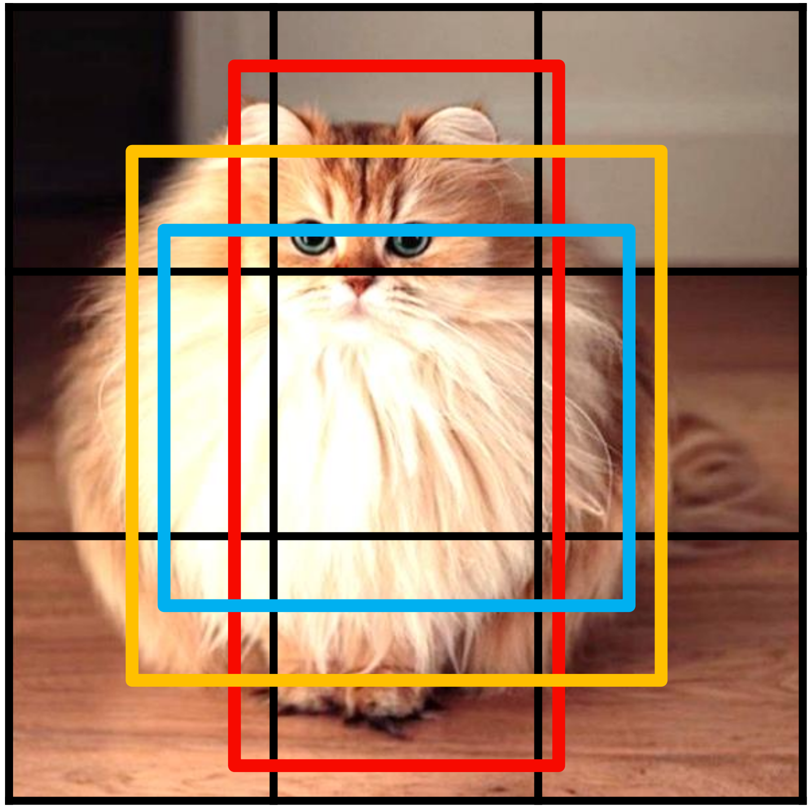

神經網路學習
調整黃色的Anchor去fit貓

黃色anchor長寬放大一點，中心稍移動

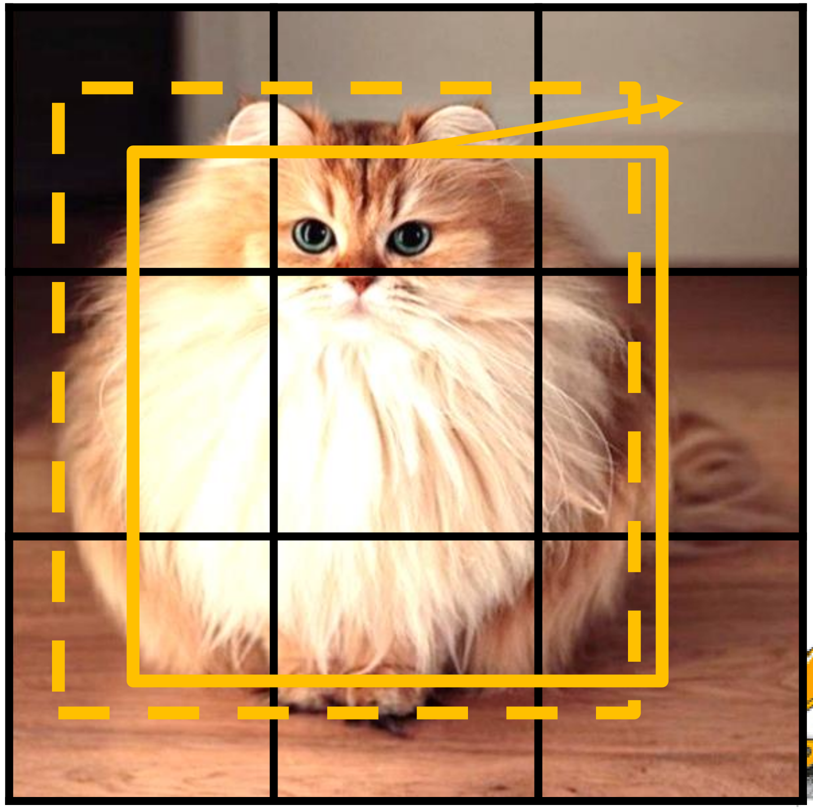

YOLO如何推算物件座標和大小

- 學習調整 Anchor (放大縮小和中心位移)
- **YOLOv2↑: (Confidence, tx, ty, tw, th)**

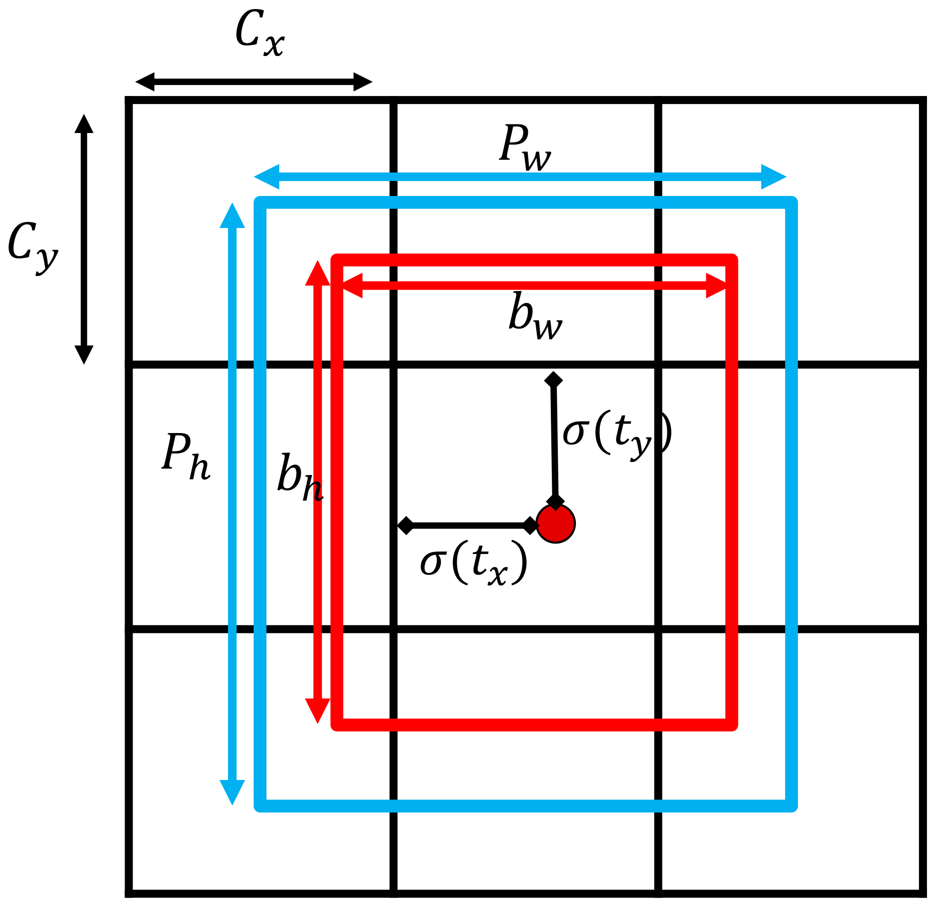

YOLO模型輸出(t_x, t_y, t_w, t_h)

模型輸出要轉換成為實際的物件中心座標(b_x, b_y)和寬高(b_w, b_h)

中心座標轉換:

$$b_x = \sigma(t_x) + C_x$$
$$b_y = \sigma(t_y) + C_y$$

寬高轉換由Anchor去進行縮放:

$$b_w = P_w e^{t_w}$$
$$b_h = P_h e^{t_h}$$

(P_w, P_h): 我們設定的Anchor寬高。

YOLO如何推算物件座標和大小

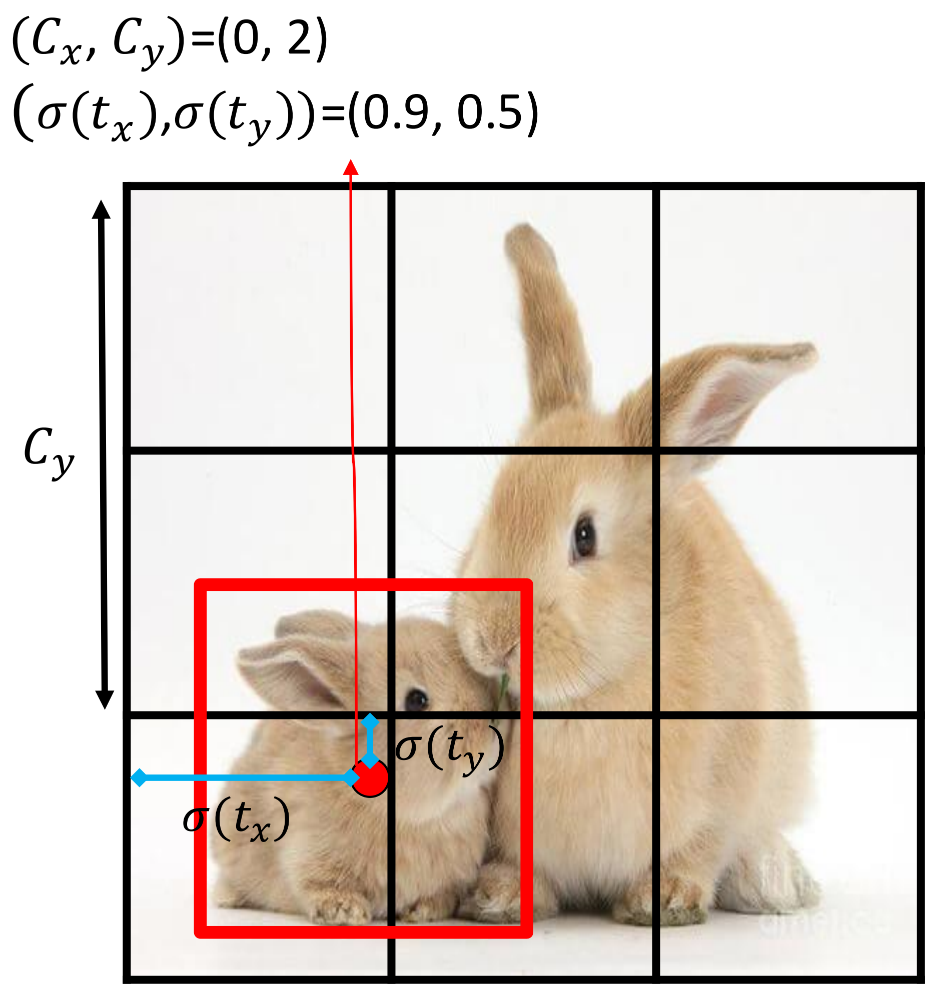

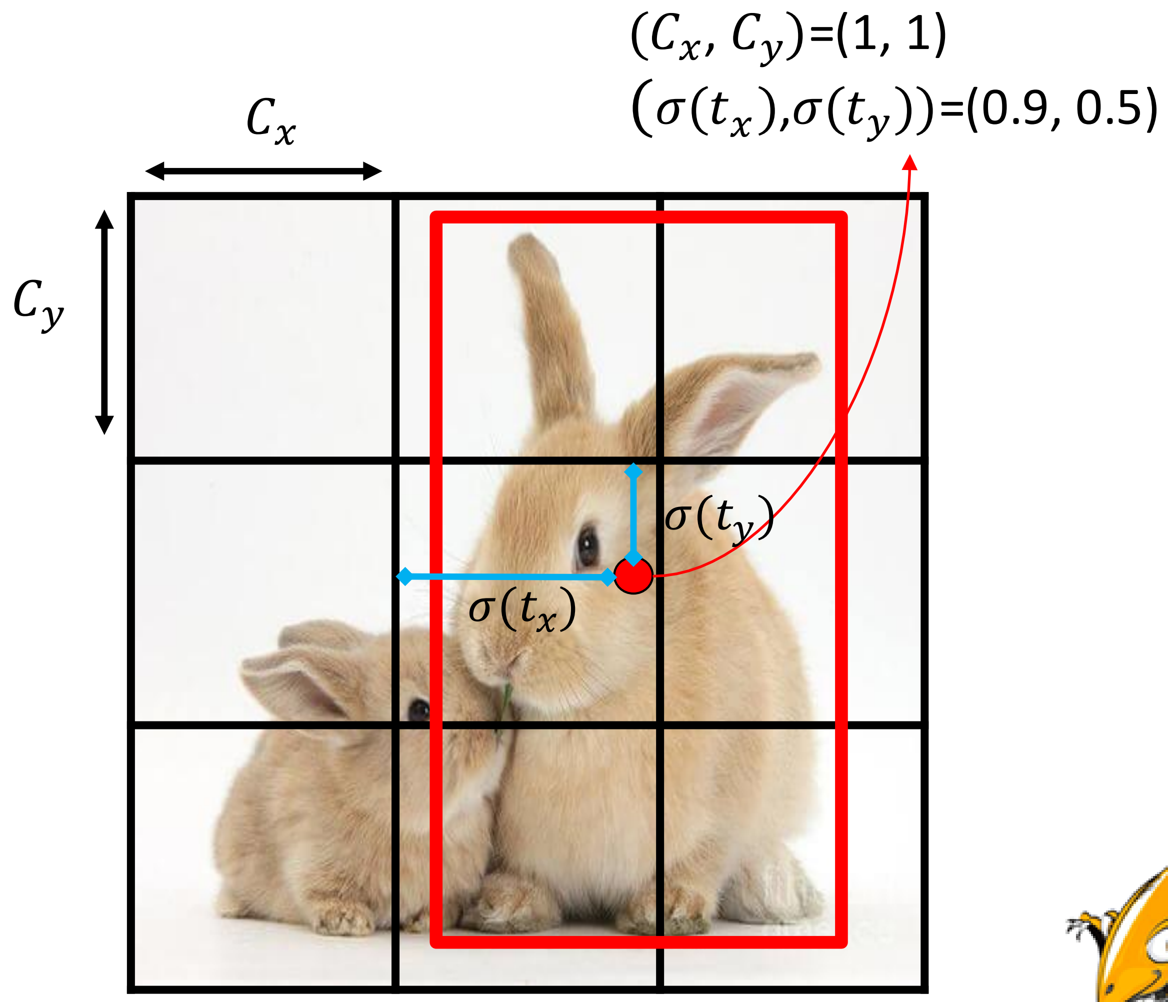

YOLO如何推算物件座標和大小

神經網路學習
調整藍色的Anchor去fit狗(兔子的紅框)

$(x, y) = (0.3, 0.7\ ) \Rightarrow (b_x, b_y) = (0.9, 2.5)$
$(w, h) = (0.4\ 0.4\ )$

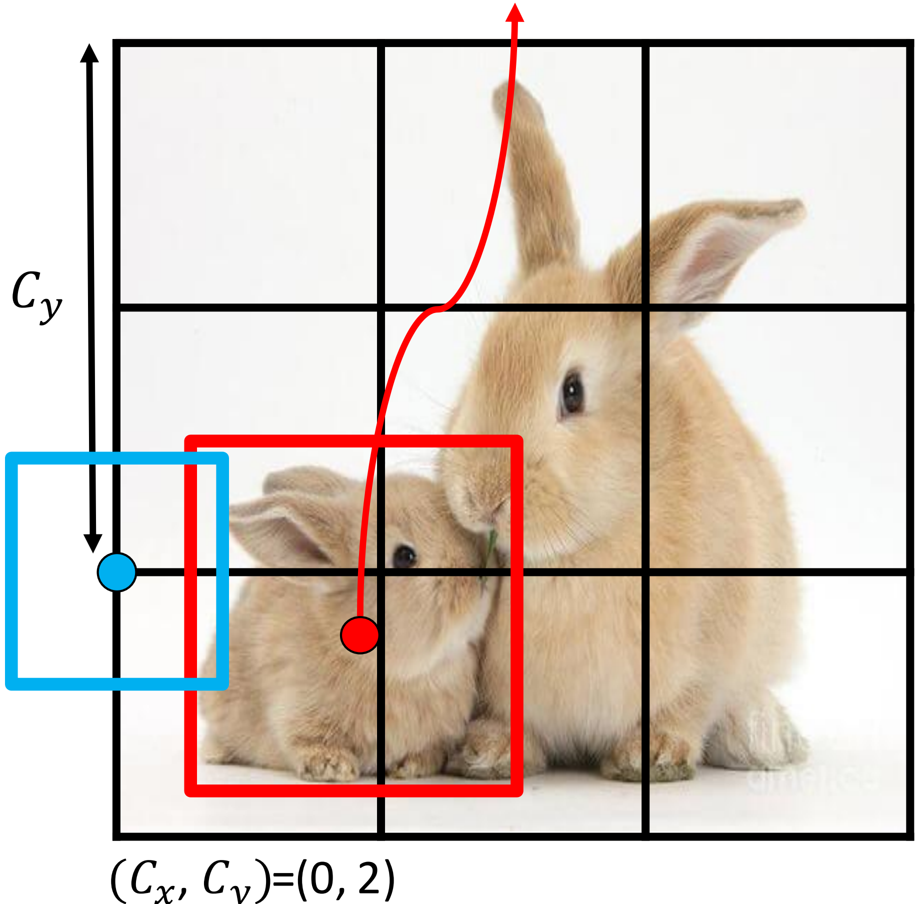

Anchor:(P_w, P_h)=(0.3, 0.3)

$$0.9 = b_x = \sigma(t_x) + C_x$$
$$2.5 = b_y = \sigma(t_y) + C_y$$
$$0.4 = b_w = P_w e^{t_w}$$
$$0.4 = b_h = P_h e^{t_h}$$

其中C_x=0, C_y=2

所以

$$\sigma(t_x) = b_x - C_x = 0.9$$
$$\sigma(t_y) = b_y - C_y = 0.5$$
$$e^{t_w} = \frac{b_w}{P_w} = \frac{0.4}{0.3} = 1.33 \Rightarrow t_w = \log(1.33)$$
$$e^{t_h} = \frac{b_h}{P_h} = \frac{0.4}{0.3} = 1.33 \Rightarrow t_h = \log(1.33)$$

YOLO如何推算物件座標和大小

神經網路學習
調整藍色的Anchor去fit狗(兔子的紅框)

$(x, y) = (0.3, 0.7\ ) \Longrightarrow (b_x, b_y) = (0.9, 2.5)$
$(w, h) = (0.4\ 0.4\ )$

C_y

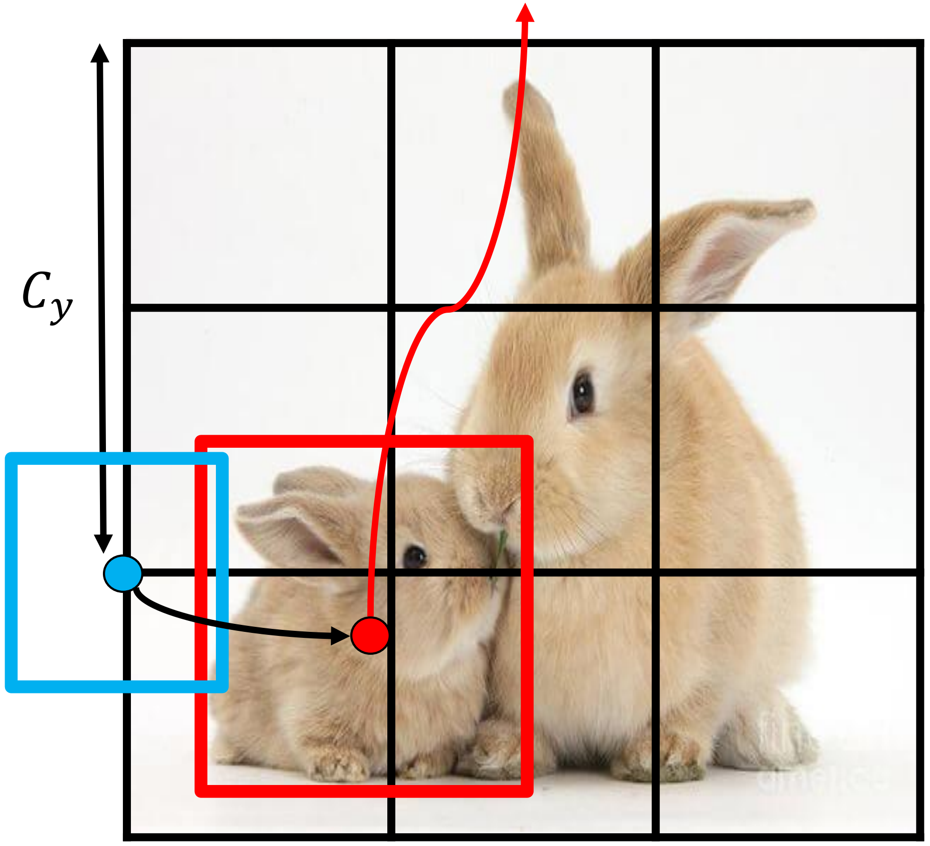

(C_x, C_y)=(0, 2)

YOLO這個物件的答案是:

$$\sigma(t_x) = 0.9$$
$$\sigma(t_y) = 0.5$$
$$t_w = \log(1.33)$$
$$t_h = \log(1.33)$$

YOLO模型輸出$(\hat{t}_x, \hat{t}_y, \hat{t}_w, \hat{t}_h)$去逼近$(t_x, t_y, t_w, t_h)$

YOLOv1和V2以上差異

YOLOv1物件實際的框$(x, y, w, h) = (0.3, 0.7, 0.4, 0.4)$

YOLOv2↑物件實際的框$\left(b_x, b_y, b_w, b_h\right) = (0.9, 2.5, 0.4, 0.4)$

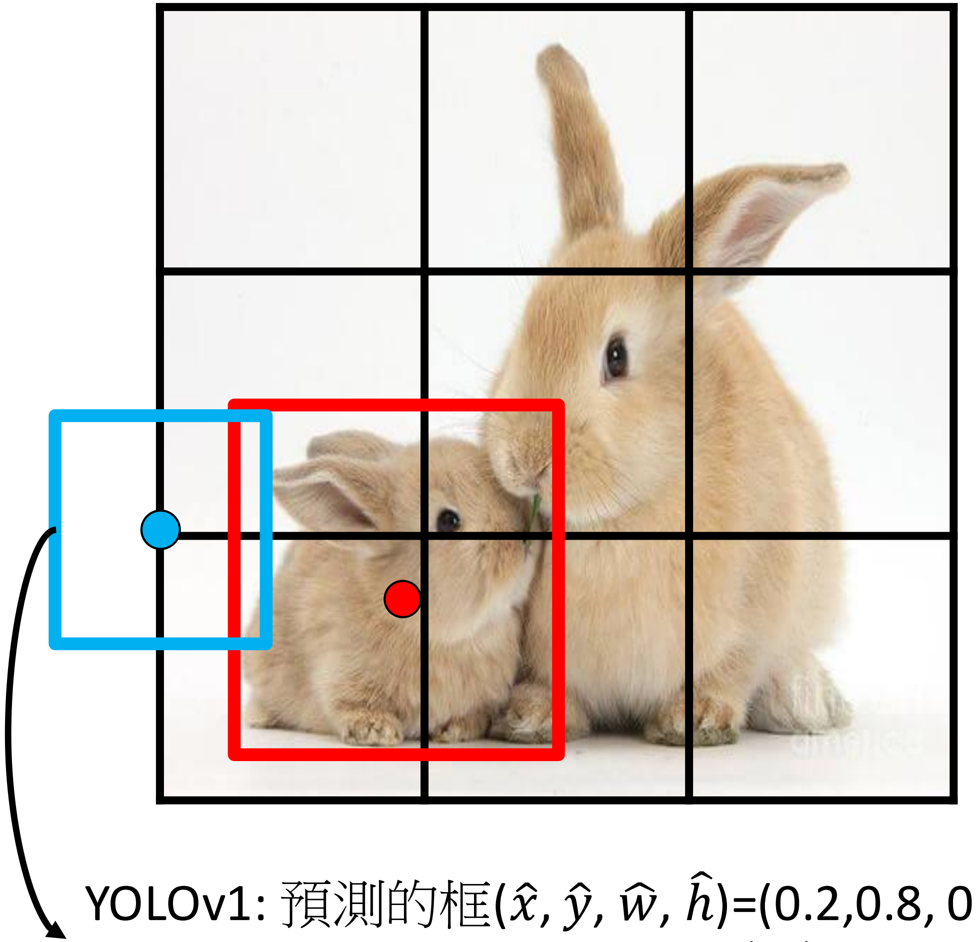

YOLOv2↑ 假設 Anchor:$(P_w, P_h)=(0.2, 0.2)$

$$b_x = \sigma(t_x) + C_x \Longrightarrow \sigma(t_x) = 0.9 - 0 = 0.9$$

$$b_y = \sigma(t_y) + C_y \Longrightarrow \sigma(t_y) = 2.5 - 2 = 0.5$$

$$0.4 = b_w = P_w e^{t_w} = 0.2e^{t_w} \Longrightarrow e^{t_w} = 2 \Longrightarrow t_w = \log(2)$$

$$0.4 = b_h = P_h e^{t_h} = 0.2e^{t_h} \Longrightarrow e^{t_h} = 2 \Longrightarrow t_h = \log(2)$$

$$(t_w - \hat{t}_w)^2 + (t_h - \hat{t}_h)^2 = 2 * (\log(2) - \log(1.5))^2 = 0.0312$$

$$loss_{v2} = 0.32 + 0.0312 = 0.3512$$

YOLOv1: 預測的框$(\hat{x}, \hat{y}, \widehat{w}, \hat{h})=(0.2, 0.8, 0.3, 0.3)$

YOLOv2↑: 預測的框$(\sigma(\hat{t}_x), \sigma(\hat{t}_y), \hat{t}_w, \hat{t}_h)=(0.5, 0.5, \log(1.5), \log(1.5))$

YOLOv3後引入Multi-scale Detection

在最後預測的S*S 的每個grid cell都預設幾個Anchors。

3*3的特徵圖

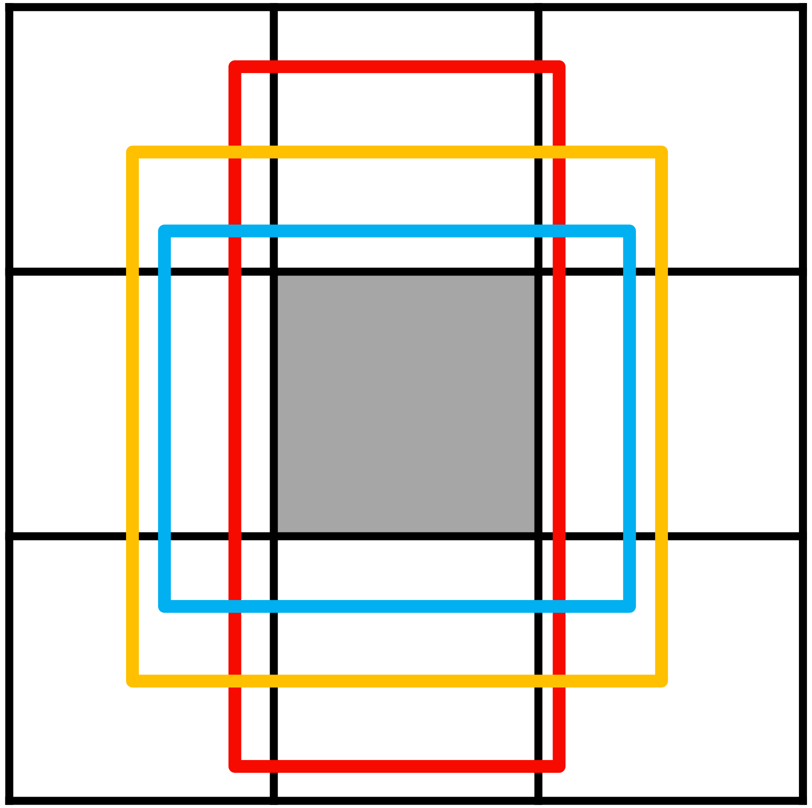

7*7的特徵圖

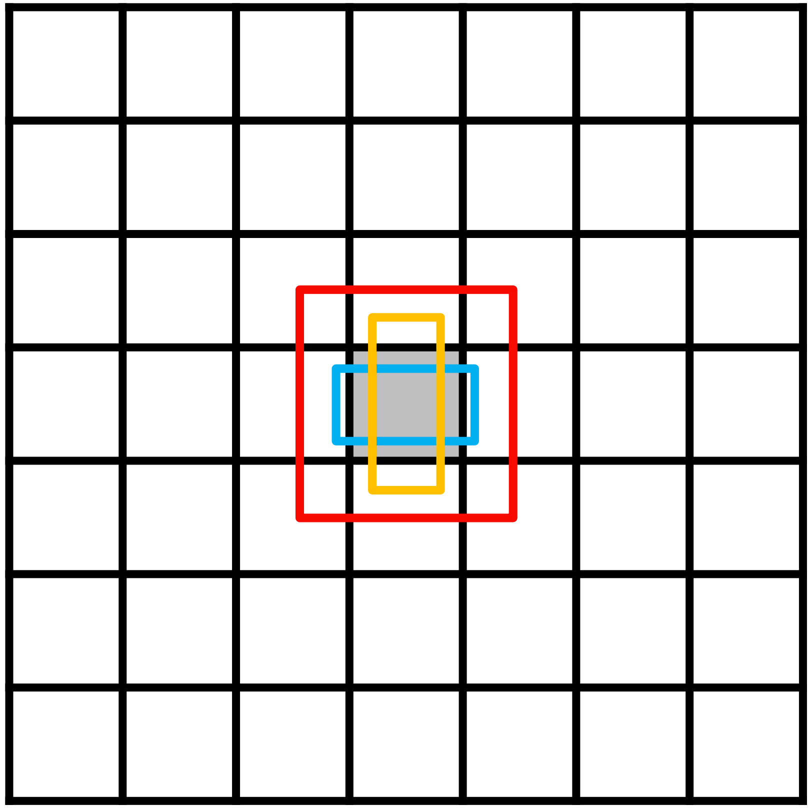

YOLOv3後引入Multi-scale Detection

在最後預測的S*S 的每個grid cell都預設幾個Anchors。

3*3的特徵圖

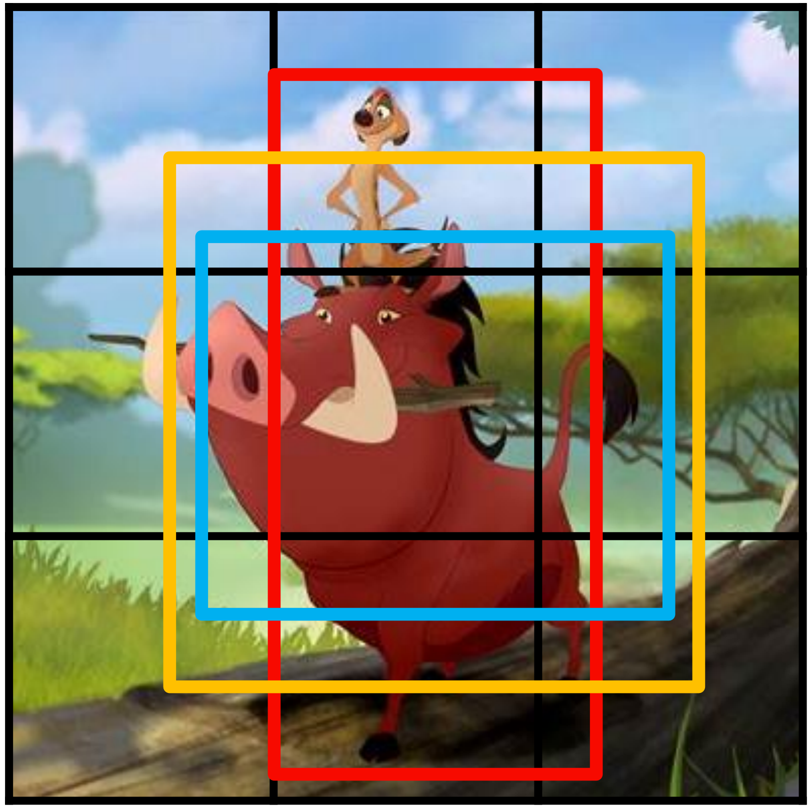

7*7的特徵圖

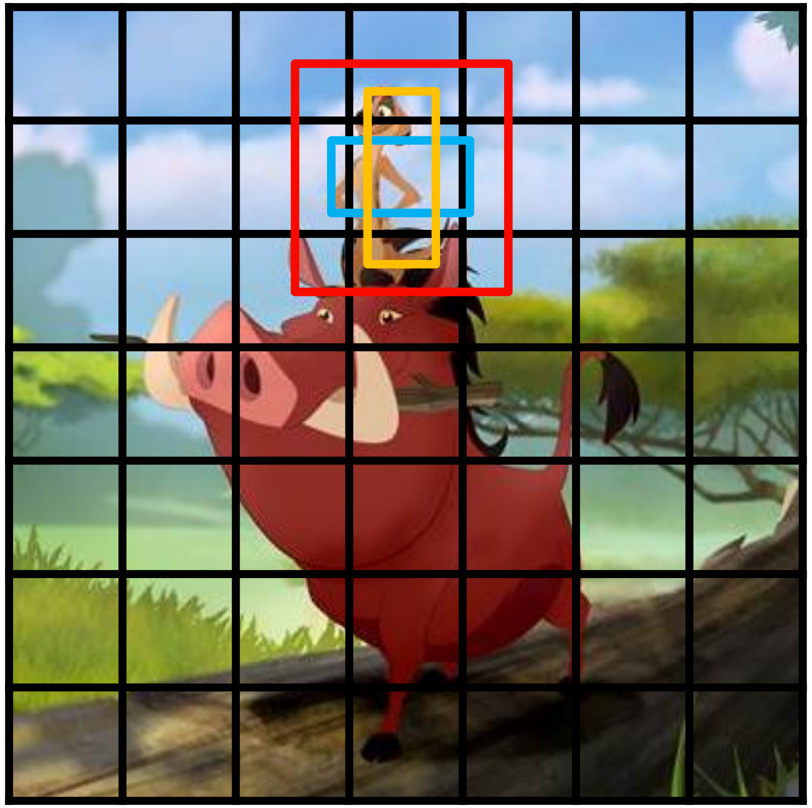

在小解析的特徵圖(3*3)適合最大物件偵測。

在大解析的特徵圖(7*7)適合最大物件偵測。

3*3特徵圖藍色的Anchor只需要微調就能fit彭彭

7*7特徵圖黃色的Anchor只需要微調就能fit丁滿

YOLOv3後引入Multi-scale Detection

人臉偵測

3*3的特徵圖

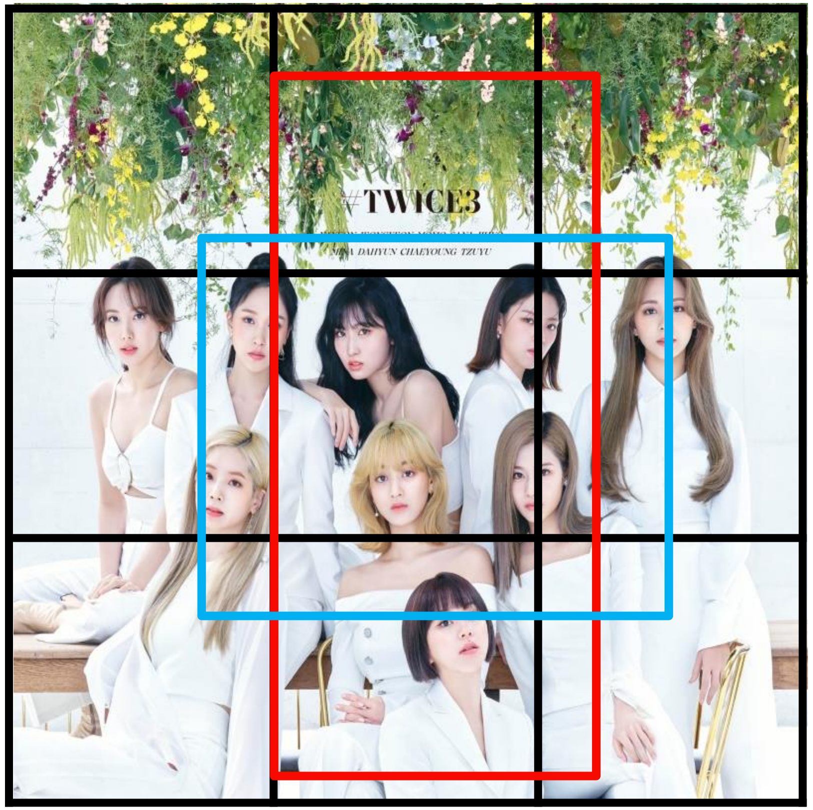

14*14的特徵圖

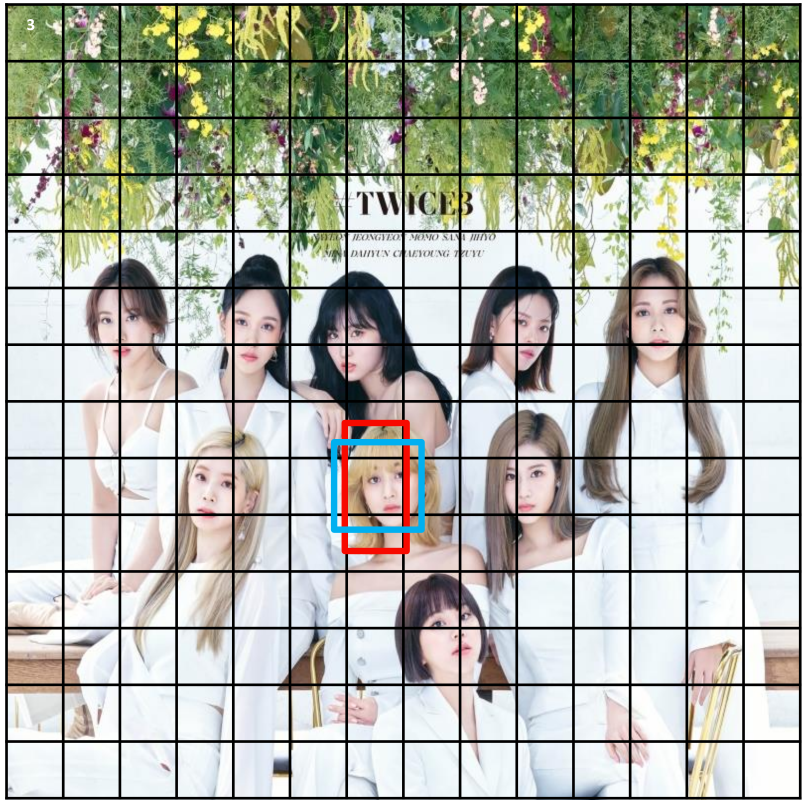

在3*3特徵圖設定的Anchor要縮小10倍，這樣的學習太難了

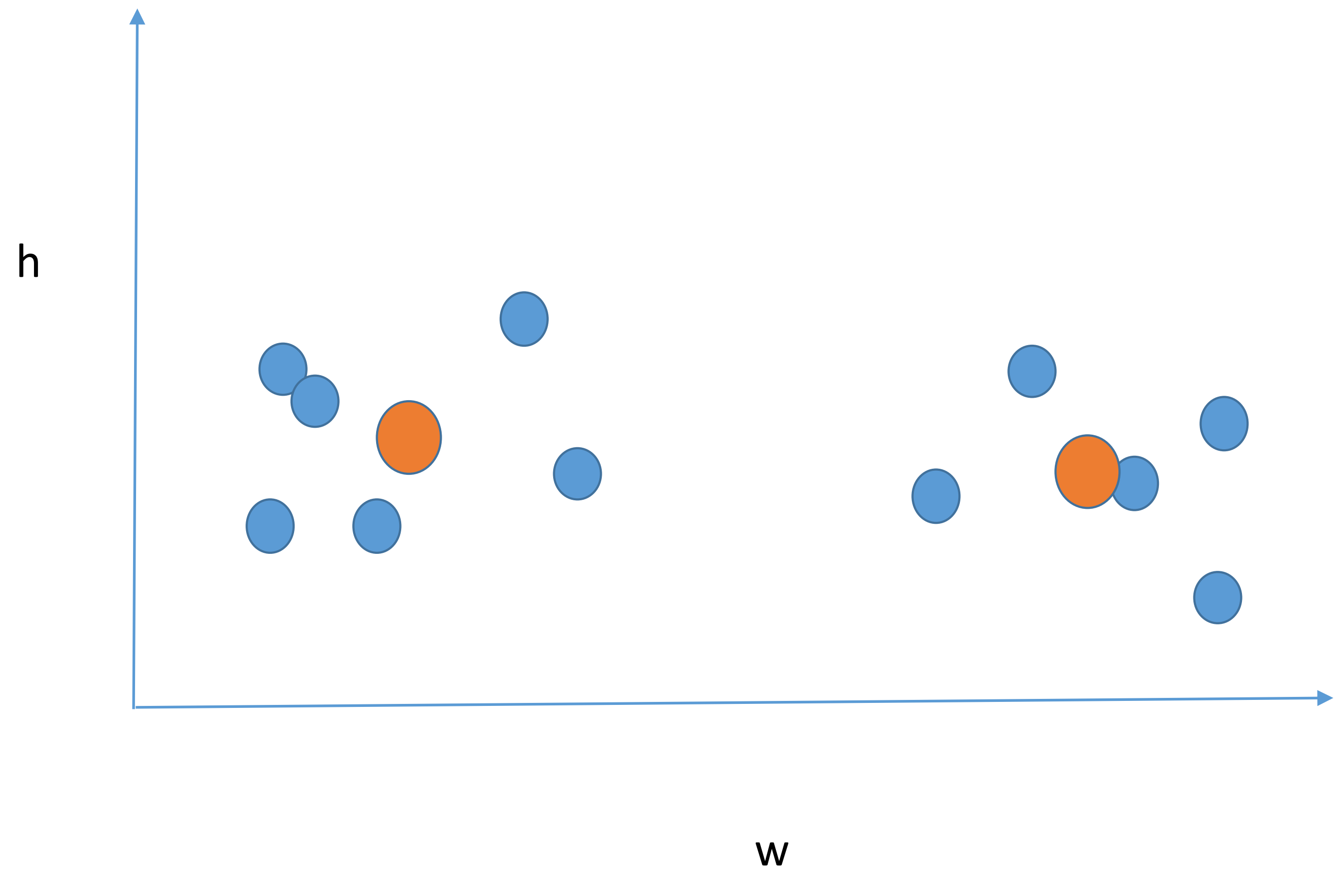
h
w